

Metro Traffic — Data Audit Report

Metro Interstate Traffic Volume — отчёт по аудиту данных

YDL 2026 · Неделя 1 · День 2 · Лабораторная «Стань детективом данных» Автор: Избасар · Дата: 2026-06-16 Датасет: Metro Interstate Traffic Volume (UCI / Kaggle) — 48 204 строки x 9 колонок, период 2012-10-02 → 2018-09-30.

1. Цель аудита

Назначение датасета — **предсказывать почасовой traffic_volume** на трассе I-94 (Миннеаполис–Сент-Пол) по погоде, времени и праздникам (задача регрессии).

Вопрос: годятся ли эти данные для такого предсказания, и где они ломаются? **Метод:** считаем дефекты в числах → проверяем синтетическим тестом, ловятся ли невозможные строки → выносим вердикт. ML-модели не строим.

2. Найденные дефекты (в числах)

Дефект	Объём	Влияние на предсказание
Пропущенные часы в ряду	11 976 (23%), в т.ч. дыра 307 дней (авг 2014 → июн 2015)	фатально для time-series: лаги и тренды рвутся на стыках
holiday пустой	99.9% (48 143 из 48 204), размечен только в 00:00	как фича почти бесполезен (шум)
Дубли по date_time	7 629 часов; трафик в дублях совпадает, но погода — нет	завышает веса; наивный keep='first' выкидывает 498 снежных часов (18%)

Дефект	Объём	Влияние на предсказание
Полностью идентичные строки	17	чистый мусор
<code>temp = 0 K</code> (абсолютный ноль)	10	битый сенсор
<code>rain_1h = 9831 мм</code> (рекорд мира ~305)	1	раздувает среднюю осадков в 2.6 раза
Снег при <code>temp > 5 °C</code>	10	внутренняя несогласованность погоды
<code>traffic_volume = 0</code>	2	возможно реально, проверено
<code>weather_description</code> дублирует <code>weather_main</code>	38 vs 11 значений, 0 расхождений	не отдельная фича, а детализация — риск двойного учёта

3. Синтетический тест: видны ли невозможные условия?

Написан валидатор `audit()` с правилами правдоподобия. В данные внедрены 6 заведомо невозможных строк:

Внедрено	Поймано
<code>temp = 0 K</code> и <code>temp = 500 K</code>	✓
<code>rain_1h = 99 999 мм</code>	✓
<code>traffic_volume = -42</code>	✓
<code>weather_main = 'Sandstorm'</code> (нет в справочнике)	✓
снег при <code>+35 °C</code>	✓
дубли по времени	✓

Вывод: все невозможные условия подсвечиваются. Проверки — рабочие guardrails: битьё ловится **до** обучения модели, а не после.

4. Три проверенных открытия

- 1. **Часы.** Пик трафика в **16:00 $\approx$ 5 709 маш/час**, минимум в **3:00 $\approx$ 373**. Проверка: в самой маленькой часовой группе **1 639** наблюдений — не случайность.
- 2. **Будни vs выходные.** В будни трафик на **+35.6%** выше (3 557 против 2 624 маш/час).
- 3. **Снег vs зима.** Наивно снег даёт -9.1% , но **внутри одной зимы эффект падает до -5.7%** — часть «эффекта снега» на деле эффект сезона (confounder). Выборка большая (2 795 часов), дело не в ней.

5. Пойманное враньё

«В праздники трафик почти исчезает — 865 маш/час».

Разоблачение: это среднее посчитано по **61 строке**, и все они приходятся на **полночь** (holiday размечен только в 00:00). Средний трафик в 00:00 по всем дням — **835 маш/час**. То есть мы сравнили *полночь со всеми часами суток*, а не праздник с обычным днём. Низкое число объясняется временем суток, а не праздником.

Правда рядом: чтобы честно измерить эффект праздника, надо метить **весь день** праздника, а не один час.

6. Вердикт: годится ли датасет для предсказания

Аспект	Оценка	Причина
Размер	ОК	$\sim$ 40 575 честных часов, 6 лет — достаточно для регрессии
Целевая traffic_volume	ОК	диапазон 0..7 280, лишь 2 нуля — чистая
Сенсоры temp/rain	чинится	11 + 1 битых строк, ловятся правилом и зануляются
Дубли	чинится	дедуп через any() по погоде
Непрерывность	ПЛОХО	дыра 307 дней + 23% часов нет

Аспект	Оценка	Причина
holiday как фича	ПЛОХО	размечен на 1 час → требует реинжиниринга
Колонки погоды	чинится	description дублирует main

Итог: - Как табличная регрессия (фичи: час, день недели, погода-флаги) — **пригоден после чистки**: сигналы сильные и проверяемые. - **Как временной ряд** (лаги, авторегрессия) — **непригоден без оговорок**: дыра 307 дней и 23% пропусков рвут последовательность. - **Для демо «как есть»** — **недостаточно хорош**: выглядит готовым к модели, но не является им. Именно поэтому он отлично подходит как учебный пример «поймай ложь в данных».

7. Открытие одной фразой

На I-94 трафик в будни на **35.6%** выше выходных, пик в **16:00 ≈ 5 709 маш/час** (в каждой часовой группе >1 600 наблюдений, дубли убраны) — это надёжно. А вывод «в праздники дорога пустеет» — **враньё**: holiday стоит только в полночь (61 строка), так что это эффект времени суток, а не праздника.

Все числа в отчёте получены из исполняемого ноутбука `Metro_Traffic_EDA.ipynb` (31 ячейка, 0 ошибок при прогоне).